



UNIVERZITET U NIŠU
ELEKTRONSKI
FAKULTET



Analiza zero-shot i N-shot pristupa velikih jezičkih modela u chatbot sistemu za rasadnik biljaka

Seminarski rad

Predmet:

Obrada prirodnih jezika

Mentor:

prof. Suzana
Stojković

Student:

Aleksandar Jovanović, br. ind. 2120

Niš, 2026. godina

SADRŽAJ

1. Uvod	4
2. Obrada prirodnih jezika (NLP)	6
2.1 Šta je NLP	6
2.2 Glavni zadaci NLP-a	6
2.3 NLP u chatbot sistemima	8
3. Veliki jezički modeli i N-shot pristup	10
3.1 Veliki jezički modeli (LLM)	10
3.2 Promptovanje velikih jezičkih modela	10
3.3 Zero-shot pristup	11
3.4 N-shot pristup	12
3.5 Prednosti N-shot pristupa u ovom radu	13
4. Opis problema i domen rasadnika biljaka	14
4.1 Definisanje problema	14
4.2 Analiza tipičnih korisničkih pitanja	14
4.3 Struktura baze biljaka	16
4.4 Struktura korisničkog upita	16
4.5 Test skup korisničkih upita	17
4.6 Ciljevi sistema	18
5. Arhitektura predloženog sistema	19
5.1 Opšti pregled sistema	19
5.2 Komponente sistema	19
5.3 Proces obrade korisničkog upita	19
5.4 Korišćenje velikog jezičkog modela	20
5.5 Generisanje odgovora	20
5.6 Prednosti predložene arhitekture	21
6. Priprema baze biljaka i test skupa upita	22
6.1 Kreiranje baze biljaka	22
6.2 Definisanje korisničkih namera	22
6.3 Definisanje uslova za preporuke	23
6.4 Kreiranje test skupa	23
6.5 Evaluacioni skup i očekivani izlaz	24
7. Implementacija sistema	25
7.1 Tehnologije i alati	25

7.2 Implementacija parsera	25
7.3 Pretraga baze biljaka.....	25
7.4 Generisanje odgovora	25
7.5 Organizacija projekta.....	26
8. Eksperimentalni rezultati i evaluacija sistema	27
8.1 Metodologija evaluacije.....	27
8.2 Eksperimentalne postavke	27
8.3 Poređenje Rule-based, LLM-only i hibridnog pristupa.....	28
8.4 Rezultati evaluacije prvog parsera i modela llama3.2:3b	30
8.5 Rezultati evaluacije krajnjeg parsera i modela qwen2.5:3b.....	30
8.6 Analiza uspešnih upita	32
8.7 Analiza grešaka	32
8.8 Diskusija rešenja.....	33
9. Mogućnosti unapređenja sistema	35
10. Zaključak.....	36

1. Uvod

U digitalnom okruženju korisnici sve češće očekuju brzu, jasnu i personalizovanu komunikaciju sa različitim vrstama sistema, servisa i poslovnih subjekata. Umesto pretrage po veb-sajtovima, katalogu proizvoda ili slanja poruka na koje se odgovor čeka duže vreme, korisnici žele da pitanje postave prirodnim jezikom i da odmah dobiju konkretan odgovor. Ovakav način komunikacije naročito je važan kod malih i srednjih preduzeća, gde vlasnici često nemaju dovoljno vremena da odgovaraju na veliki broj ponavljajućih pitanja kupaca. Tipični primeri takvih pitanja odnose se na cenu proizvoda, dostupnost, radno vreme, lokaciju, dostavu ili preporuku određenog proizvoda prema potrebama korisnika.

U oblasti rasadnika i prodaje biljaka, ovakva potreba je posebno izražena. Kupci često ne znaju tačan naziv biljke koja im je potrebna, već pitanje formulišu opisno, na primer: „Treba mi biljka za balkon na suncu”, „Koje biljke ne traže mnogo vode?” ili „Šta preporučujete za živu ogradu?”. Sa druge strane, postoje i jednostavnija pitanja, kao što su: „Koliko košta lavanda?”, „Imate li muškate?” ili „Da li dostavljate za Vranje?”. Ovakvi upiti su prirodni za čoveka, ali za računar predstavljaju problem razumevanja prirodnog jezika, jer se ista namera može izraziti na mnogo različitih načina.

Razvoj chatbot sistema predstavlja jedan od najvidljivijih primera primene obrade prirodnih jezika u praksi. Prve generacije chatbotova bile su uglavnom zasnovane na pravilima, šablonima i unapred definisanim odgovorima. Takvi sistemi mogli su da funkcionišu samo ako korisnik postavi pitanje u očekivanom obliku. Na primer, ako sistem očekuje pitanje „Koliko košta lavanda?”, on možda neće pravilno razumeti pitanja poput „Pošto je lavanda?”, „Koliko para je lavanda?” ili „Možete li mi reći cenu lavande?”. Ograničenje takvog pristupa je u tome što se mora ručno predvideti veliki broj mogućih formulacija, što postaje nepraktično čim domen postane malo složeniji.

Savremeni pristupi se sve više oslanjaju na velike jezičke modele, koji mogu da razumeju značenje rečenice i onda kada korisnik ne koristi tačno istu formulaciju kao u primerima. Umesto da se sistem zasniva samo na ručno napisanim pravilima, veliki jezički model može da prepozna nameru korisnika, izdvoji naziv biljke, uslove koje korisnik navodi i eventualnu lokaciju. Na taj način moguće je napraviti sistem koji ne traži identično pitanje u bazi, već pokušava da razume šta korisnik zaista želi. Ovo je posebno važno za srpski jezik, gde padeži, sinonimi, red reči i neformalni izrazi mogu značajno promeniti površinski oblik rečenice, iako značenje ostaje isto.

Jedan od osnovnih problema u razumevanju prirodnog jezika jeste višeznačnost. Korisnik može postaviti kratko pitanje, nepotpunu rečenicu ili pitanje koje sadrži više namera istovremeno. Na primer, pitanje „Imate li lavandu i koliko košta?” sadrži dve namere: proveru dostupnosti i proveru cene. Pitanje „Nemam mnogo sunca na balkonu” ne sadrži direktno reč „senka”, ali sistem treba da zaključi da korisnik traži biljku koja može da uspeva u uslovima slabijeg osvetljenja. Slično tome, pitanje „Nemam vremena za često zalivanje” treba povezati sa uslovom „malo vode”. Ovi primeri pokazuju da zadatak nije samo prepoznavanje ključnih reči, već razumevanje značenja iskaza.

Obrada prirodnih jezika, odnosno NLP, ima ključnu ulogu u rešavanju ovakvih problema. NLP omogućava računarskim sistemima da analiziraju tekst pisan prirodnim jezikom, prepoznaju obrasce, izvuku relevantne informacije i pretvore neuređen tekst u strukturisani oblik pogodan za dalju obradu. U ovom radu NLP se koristi za razumevanje korisničkih upita u domenu rasadnika

biljaka. Ulaz u sistem je pitanje korisnika napisano na srpskom jeziku, dok je izlaz strukturisan JSON objekat koji sadrži nameru korisnika, naziv biljke ako se pominje, uslove koje biljka treba da ispuni i lokaciju ako je navedena.

Cilj ovog rada je razvoj i evaluacija jednostavnog, ali funkcionalnog NLP sistema za razumevanje korisničkih upita u domenu rasadnika biljaka. Sistem ne koristi klasičan pristup treniranja modela mašinskog učenja nad velikim obeleženim skupom podataka, već koristi veliki jezički model kroz zero-shot i N-shot pristupe. Na ovaj način se ispituje koliko dobro model može da razume korisničke upite bez dodatnog treniranja, kao i da li dodavanje malog broja primera u prompt poboljšava rezultate. Ovakav pristup je praktičan u situacijama kada nije dostupno nekoliko hiljada obeleženih primera, što je čest slučaj u uskim i lokalnim domenima.

U okviru rada razvijen je skup biljaka u CSV formatu, koji predstavlja jednostavnu bazu znanja sistema. Za svaku biljku definisani su atributi kao što su naziv, cena, period dostupnosti, visina, potreba za suncem, potreba za vodom, tip biljke, nega i opis. Pored toga, kreiran je test skup korisničkih upita na srpskom jeziku. Ovaj skup se ne koristi za treniranje modela, već isključivo za evaluaciju. Na osnovu njega meri se tačnost prepoznavanja namere, tačnost izdvajanja biljke, tačnost izdvajanja uslova i ukupna tačnost generisanog JSON izlaza.

Posebna pažnja posvećena je poređenju zero-shot i N-shot pristupa. U zero-shot varijanti model dobija samo opis zadatka i pravila, bez konkretnih primera. U one-shot, three-shot i five-shot varijantama model dobija jedan, tri ili pet primera ulaza i očekivanog izlaza. Na taj način se može analizirati da li i koliko dodavanje primera u prompt utiče na performanse sistema. Ovakav eksperiment je posebno značajan jer pokazuje da se u određenim praktičnim domenima mogu postići korisni rezultati i bez klasičnog treniranja modela, oslanjanjem na sposobnost velikih jezičkih modela da generalizuju na osnovu opisa zadatka i malog broja primera.

Pored same ekstrakcije informacija iz korisničkog upita, sistem generiše i konačan odgovor korisniku. Generisanje odgovora ne obavlja se direktno pomoću LLM-a, već šablonski, na osnovu podataka iz CSV baze. Na primer, ako model prepozna da korisnik pita za cenu lavande, sistem iz baze pronalazi cenu i vraća odgovor: „Lavanda košta 250 dinara.” Ako korisnik traži preporuku za biljku koja voli sunce i ne traži mnogo vode, sistem pretražuje bazu i rangira biljke prema tome koliko dobro odgovaraju zadatim uslovima. Ovakav pristup smanjuje rizik od netačnih ili izmišljenih odgovora, jer se konkretne informacije uvek preuzimaju iz lokalne baze.

Rad je organizovan na sledeći način. U drugom poglavlju objašnjavaju se osnovni pojmovi obrade prirodnih jezika i njihova primena u chatbot sistemima. Treće poglavlje posvećeno je velikim jezičkim modelima, njihovim karakteristikama, prednostima i ograničenjima. U četvrtom poglavlju objašnjavaju se zero-shot, one-shot i N-shot pristupi. Peto poglavlje opisuje konkretan problem korisničkih upita u domenu rasadnika biljaka. U šestom poglavlju predstavljena je arhitektura predloženog sistema, dok se sedmo poglavlje bavi implementacijom parsera, CSV baze i generatora odgovora. Osmo poglavlje opisuje eksperimentalno okruženje i korišćene alate. Zatim su prikazani rezultati evaluacije, poređenja pristupa i analiza grešaka. Na kraju, razmatraju se mogući pravci unapređenja sistema i daje zaključak rada.

2. Obrada prirodnih jezika (NLP)

2.1 Šta je NLP

Obrada prirodnih jezika (Natural Language Processing – NLP) predstavlja oblast veštačke inteligencije koja se bavi razumevanjem, analizom i generisanjem ljudskog jezika pomoću računara. Cilj NLP sistema je da omogući računarima da obrađuju tekst ili govor na način koji je što sličniji ljudskom razumevanju jezika. Za razliku od programskih jezika, koji imaju strogo definisanu sintaksu i pravila, prirodni jezici su veoma složeni, često dvosmisleni i prepuni različitih jezičkih konstrukcija, sinonima i izuzetaka.

Ljudi svakodnevno koriste prirodni jezik za komunikaciju, izražavanje želja, postavljanje pitanja i razmenu informacija. Kada čovek pročita rečenicu poput „Treba mi biljka za balkon na suncu“, veoma lako razume da sagovornik traži preporuku biljke koja uspeva u uslovima jakog osvetljenja i pogodna je za uzgoj na balkonu. Računar, međutim, ne poseduje intuitivno razumevanje jezika i zbog toga je potrebno razviti metode koje će tekst pretvoriti u oblik pogodan za obradu.

Obrada prirodnih jezika povezuje više oblasti računarskih nauka, uključujući veštačku inteligenciju, mašinsko učenje, lingvistiku i statistiku. Tokom razvoja ove oblasti korišćeni su različiti pristupi, od sistema zasnovanih na pravilima do savremenih modela dubokog učenja.

Istorijski razvoj NLP-a može se podeliti na nekoliko značajnih faza. U ranim fazama razvoja računarskih sistema dominirali su sistemi zasnovani na ručno definisanim pravilima. Stručnjaci su morali da definišu veliki broj gramatičkih pravila, rečnika i obrazaca koji su omogućavali računaru da prepozna određene konstrukcije u jeziku. Ovakav pristup bio je veoma zahtevan za održavanje i teško se prilagođavao novim domenima.

Kasnije se razvijaju statistički modeli koji koriste velike količine podataka za učenje obrazaca u jeziku. Umesto ručnog definisanja svih pravila, sistemi su počeli da koriste verovatnoće i statističke metode kako bi donosili odluke o značenju reči i rečenica. Razvoj mašinskog učenja dodatno je unapredio performanse NLP sistema.

Poslednjih godina najveći napredak doneli su modeli zasnovani na dubokim neuronskim mrežama i transformator arhitekturi. Ovi modeli mogu da analiziraju ogromne količine tekstualnih podataka i nauče složene odnose između reči, fraza i rečenica. Zahvaljujući tome, savremeni veliki jezički modeli postižu rezultate koji su značajno bolji od prethodnih pristupa u zadacima kao što su klasifikacija teksta, prevođenje, odgovaranje na pitanja i generisanje teksta.

2.2 Glavni zadaci NLP-a

Obrada prirodnih jezika obuhvata veliki broj različitih zadataka. Iako se konkretna implementacija razlikuje od sistema do sistema, većina NLP aplikacija koristi neke od osnovnih koraka obrade teksta.

Tokenizacija

Tokenizacija predstavlja proces razdvajanja teksta na manje jedinice koje nazivamo tokeni.

Token može biti reč, broj, znak interpunkcije ili drugi element teksta.

Na primer, rečenica:

„Koliko košta lavanda?“

nakon tokenizacije može biti predstavljena kao:

["Koliko", "košta", "lavanda", "?"]

Tokenizacija predstavlja jedan od osnovnih koraka obrade teksta jer omogućava dalju analizu pojedinačnih delova rečenice. Bez tokenizacije računar posmatra tekst kao jedan niz karaktera, što otežava razumevanje njegovog značenja.

Lematizacija

Lematizacija predstavlja postupak svođenja različitih oblika iste reči na njen osnovni oblik, odnosno lemu. Ovaj postupak je posebno značajan kod jezika sa bogatom morfologijom, kao što je srpski jezik.

Na primer:

- lavanda
- lavande
- lavandu

predstavljaju različite gramatičke oblike iste reči.

Nakon lematizacije svi navedeni oblici mogu biti predstavljeni jedinstvenim oblikom:

lavanda

Lematizacija omogućava sistemu da prepozna da se različiti padežni oblici odnose na isti pojam, čime se povećava tačnost pretrage i klasifikacije.

POS Tagging

POS tagging (Part-of-Speech Tagging) predstavlja proces određivanja gramatičke kategorije svake reči u rečenici. Sistem pokušava da odredi da li je određena reč imenica, glagol, pridev, prilog ili neka druga vrsta reči.

Na primer, za rečenicu:

„Lavanda voli sunce“

moguće oznake bile bi:

- Lavanda – imenica
- voli – glagol
- sunce – imenica

Ovaj zadatak omogućava bolje razumevanje strukture rečenice i često predstavlja osnovu za složenije NLP metode.

Named Entity Recognition (NER)

Named Entity Recognition (NER) predstavlja zadatak automatskog prepoznavanja i klasifikacije važnih entiteta u tekstu.

Tipični entiteti uključuju:

- osobe,
- organizacije,
- gradove,
- države,
- datume,
- proizvode.

Na primer, u rečenici:

„Da li dostavljate za Vranje?“

sistem treba da prepozna da je „Vranje“ naziv lokacije.

U okviru ovog rada prepoznavanje lokacija ima važnu ulogu jer omogućava sistemu da izdvoji grad za koji korisnik traži dostavu.

Klasifikacija teksta

Klasifikacija teksta predstavlja jedan od najčešćih zadataka obrade prirodnih jezika. Cilj je dodeliti tekstu jednu ili više unapred definisanih kategorija.

Primer klasifikacije u okviru ovog rada:

- „Koliko košta lavanda?“ → cena
- „Imate li lavandu?“ → dostupnost
- „Treba mi biljka za balkon.“ → preporuka
- „Da li dostavljate za Vranje?“ → dostava

Prepoznavanje korisničke namere zapravo predstavlja poseban oblik klasifikacije teksta.

Ekstrakcija informacija

Ekstrakcija informacija podrazumeva automatsko izdvajanje važnih podataka iz neuređenog teksta.

Na primer, iz upita:

„Treba mi biljka za balkon na suncu koja ne traži mnogo vode.“

sistem može izdvojiti:

- balkon
- sunce
- malo vode

Ovakvi podaci se zatim mogu koristiti za pretragu baze biljaka i generisanje preporuka.

U ovom radu ekstrakcija informacija predstavlja jedan od ključnih koraka jer omogućava prelazak sa slobodnog teksta na strukturisani JSON zapis.

2.3 NLP u chatbot sistemima

Jedna od najvažnijih primena obrade prirodnih jezika danas jesu chatbot sistemi. Chatbot

predstavlja softverski sistem koji omogućava komunikaciju sa korisnikom putem prirodnog jezika.

Savremeni chatbot sistemi koriste NLP tehnike kako bi razumeli korisnički upit, izdvojili relevantne informacije i generisali odgovarajući odgovor.

Razumevanje korisničke namere

Prvi korak u radu chatbot sistema jeste razumevanje namere korisnika. Sistem mora da utvrdi šta korisnik zapravo želi da postigne postavljanjem određenog pitanja.

Na primer:

„Koliko košta lavanda?“

predstavlja zahtev za informacijom o ceni.

Sa druge strane:

„Treba mi biljka za živu ogradu.“

predstavlja zahtev za preporukom.

Prepoznavanje namere omogućava sistemu da odredi koji deo baze podataka treba pretražiti i kakav odgovor treba generisati.

U okviru ovog rada prepoznaju se različite namere kao što su cena, dostupnost, preporuka, informacije, lokacija i dostava.

Generisanje odgovora

Nakon razumevanja korisničkog pitanja potrebno je generisati odgovor. Postoje dva osnovna pristupa.

Prvi pristup podrazumeva korišćenje unapred definisanih šablona. U ovom slučaju sistem pronalazi relevantne podatke i ubacuje ih u odgovarajući tekstualni obrazac.

Na primer:

„Lavanda košta 250 dinara.“

Drugi pristup koristi velike jezičke modele za generisanje prirodnijih i fleksibilnijih odgovora.

U ovom radu primenjen je kombinovani pristup. Veliki jezički model koristi se za razumevanje korisničkog upita i ekstrakciju strukturisanih informacija, dok se konačni odgovor generiše na osnovu podataka iz lokalne baze biljaka. Na taj način se obezbeđuje da odgovori budu tačni, konzistentni i zasnovani na stvarnim podacima, uz istovremeno korišćenje prednosti savremenih NLP tehnika za razumevanje prirodnog jezika.

3. Veliki jezički modeli i N-shot pristup

3.1 Veliki jezički modeli (LLM)

Poslednjih godina oblast obrade prirodnih jezika doživela je značajan napredak zahvaljujući razvoju velikih jezičkih modela (Large Language Models – LLM). Ovi modeli predstavljaju napredne neuronske mreže koje su trenirane na ogromnim količinama tekstualnih podataka prikupljenih iz knjiga, članaka, internet stranica i drugih izvora. Tokom procesa treniranja model uči obrasce jezika, odnose između reči, gramatičke strukture i semantičke veze koje omogućavaju razumevanje i generisanje teksta.

Za razliku od tradicionalnih NLP sistema koji su se oslanjali na ručno definisana pravila ili posebno trenirane klasifikatore za svaki zadatak, veliki jezički modeli mogu da rešavaju veliki broj različitih problema bez dodatnog treniranja. Jedan isti model može da odgovara na pitanja, prevodi tekst, klasifikuje dokumente, generiše sadržaj ili izvlači informacije iz korisničkih upita. Osnovu savremenih LLM sistema čini transformator arhitektura (Transformer), predstavljena 2017. godine u radu „Attention Is All You Need“. Najvažnija karakteristika transformatora jeste mehanizam pažnje (attention mechanism), koji omogućava modelu da analizira odnose između svih reči u rečenici bez obzira na njihovu udaljenost.

Na primer, u rečenici:

„Treba mi biljka za balkon koja ne traži mnogo vode.“

model može da poveže izraz „ne traži mnogo vode“ sa zahtevom za biljkama koje podnose sušu i zahtevaju retko zalivanje. Ovakve veze često je teško ručno definisati pomoću pravila, dok ih veliki jezički modeli uče tokom procesa treniranja.

Danas postoji veliki broj poznatih LLM modela, među kojima su GPT, Llama, Mistral, Gemma i drugi. Neki modeli su komercijalni i dostupni putem API servisa, dok su drugi otvorenog koda i mogu se pokretati lokalno na računaru korisnika.

U okviru ovog rada korišćen je najpre model Llama 3.2:3B, pokrenut lokalno pomoću platforme Ollama. Za zvaničan rad je kasnije korišćen qwen2.5:3b model. Prednost ovakvog pristupa jeste mogućnost rada bez internet konekcije i bez troškova korišćenja komercijalnih API servisa. Takođe, svi podaci ostaju lokalno na računaru, što može biti značajno u aplikacijama koje obrađuju osetljive informacije.

3.2 Promptovanje velikih jezičkih modela

Jedna od najvažnijih karakteristika velikih jezičkih modela jeste mogućnost izvršavanja zadataka na osnovu instrukcija koje korisnik prosledi kroz prompt.

Prompt predstavlja tekstualni opis zadatka koji model treba da izvrši. Kvalitet prompta direktno utiče na kvalitet rezultata koje model generiše.

Na primer, ukoliko modelu pošaljemo upit:

„Koliko košta lavanda?“

on može odgovoriti na različite načine u zavisnosti od toga kako je formulisan sistemski prompt.

U okviru ovog rada model nije korišćen za generisanje slobodnog teksta, već za pretvaranje korisničkog pitanja u strukturisani JSON zapis.

Primer željenog izlaza:

```
{
  "namere": ["cena"],
  "biljka": "lavanda",
  "uslovi": [],
  "lokacija": null
}
```

Da bi model dosledno generisao ovakav izlaz, kreiran je detaljan sistemski prompt koji sadrži:

- opis zadatka,
- dozvoljene namere,
- dozvoljene uslove,
- pravila za ekstrakciju podataka,
- primere očekivanih odgovora.

Na ovaj način model dobija dovoljno informacija da razume kako treba da obradi korisnički upit. Kvalitet prompta predstavlja jedan od najvažnijih faktora uspešnosti sistema. Loše definisan prompt može dovesti do nedoslednih odgovora, dok pažljivo dizajniran prompt značajno poboljšava performanse modela.

3.3 Zero-shot pristup

Zero-shot learning predstavlja pristup u kome model rešava zadatak bez konkretnih primera u promptu.

Model dobija samo opis problema i pravila koja treba da prati.

Primer zero-shot prompta:

Ti si parser korisničkih upita za rasadnik biljaka.

Vrati JSON sa:

- namerom
- biljkom
- uslovima
- lokacijom

U ovom slučaju model nema prikazane primere kako treba da izgleda izlaz.

Prednost zero-shot pristupa jeste jednostavnost implementacije. Potrebno je samo definisati zadatak i poslati korisnički upit modelu.

Međutim, zbog nedostatka primera model može različito interpretirati korisničke zahteve, što dovodi do većeg broja grešaka.

U eksperimentima sprovedenim u ovom radu zero-shot pristup pokazao je veoma dobre rezultate u prepoznavanju korisničke namere, ali slabije rezultate u prepoznavanju biljaka i izdvajanju uslova.

Posebno su se javljale greške kod:

- padežnih oblika naziva biljaka,

- sinonima,
- složenih preporuka,
- kombinovanih pitanja.

3.4 N-shot pristup

Few-shot learning predstavlja pristup u kome se modelu prikazuje mali broj primera pre izvršavanja zadatka.

Na primer:

Primer 1

Upit:

„Koliko košta lavanda?“

Izlaz:

```
{
  "namere":["cena"],
  "biljka":"lavanda",
  "uslovi":[],
  "lokacija":null
}
```

Primer 2

Upit:

„Imate li muškatle?“

Izlaz:

```
{
  "namere":["dostupnost"],
  "biljka":"muskatla",
  "uslovi":[],
  "lokacija":null
}
```

Nakon nekoliko primera model dobija novi korisnički upit koji treba da obradi.

Ideja few-shot pristupa jeste da model kroz primere bolje razume očekivani format odgovora i način rešavanja zadatka.

Kada broj primera raste, često se koristi termin N-shot learning.

Na primer:

- 1-shot → jedan primer,
- 3-shot → tri primera,
- 5-shot → pet primera,
- 10-shot → deset primera.

U okviru ovog rada implementirane su pet verzije sistema:

- Zero-shot
- One-shot

- Three-shot
- Five-shot
- Few(ten)-shot

Sve verzije koriste isti model i istu bazu podataka, dok se razlikuju samo po broju primera prikazanih u promptu.

3.5 Prednosti N-shot pristupa u ovom radu

Osnovna ideja rada jeste ispitivanje da li dodavanje primera u prompt poboljšava razumevanje korisničkih pitanja.

Za domen rasadnika biljaka korisnici često koriste različite formulacije:

- „Pošto je lavanda?“
- „Koliko košta lavanda?“
- „Za koliko prodajete lavandu?“

Iako sva pitanja imaju isto značenje, model može različito reagovati ukoliko nije dovoljno dobro usmeren.

Dodavanjem primera model dobija jasniju predstavu o očekivanom ponašanju.

Takođe, few-shot pristup omogućava bolje rešavanje složenijih slučajeva:

Kombinovano pitanje

„Imate li lavandu i koliko košta?“

Željeni izlaz:

```
{
  "namere":["dostupnost","cena"],
  "biljka":"lavanda",
  "uslovi":[],
  "lokacija":null
}
```

Ovakvi primeri pomažu modelu da nauči da jedan upit može sadržati više namera istovremeno.

Na osnovu rezultata eksperimenta prikazanih u kasnijim poglavljima može se analizirati da li povećanje broja primera zaista dovodi do boljih performansi sistema i u kojim aspektima dolazi do najvećih poboljšanja.

4. Opis problema i domen rasadnika biljaka

4.1 Definisanje problema

U svakodnevnom radu rasadnika veliki broj korisnika postavlja slična pitanja u vezi sa dostupnošću biljaka, cenama, uslovima gajenja, preporukama za određene lokacije i mogućnostima dostave. Većina ovih pitanja dolazi putem telefona, društvenih mreža ili aplikacija za razmenu poruka. Odgovaranje na veliki broj ponavljajućih pitanja zahteva vreme i angažovanje zaposlenih, što može predstavljati problem naročito u periodima povećane prodaje. Razvoj chatbot sistema koji može automatski da odgovara na najčešća pitanja kupaca predstavlja zanimljivu primenu obrade prirodnih jezika. Takav sistem omogućava korisnicima da brzo dobiju informacije bez potrebe za direktnom komunikacijom sa prodavcem, dok rasadniku omogućava automatizaciju dela poslovnih procesa.

Osnovni problem koji se rešava u ovom radu jeste razumevanje korisničkih upita napisanih prirodnim jezikom na srpskom jeziku. Korisnici mogu postavljati pitanja na mnogo različitih načina, koristiti sinonime, dijalekte, gramatičke varijacije i neformalne izraze. Zbog toga sistem mora biti dovoljno fleksibilan da razume različite formulacije koje imaju isto značenje.

Na primer, sledeći upiti imaju istu nameru:

- Koliko košta lavanda?
- Pošto je lavanda?
- Koliko para je lavanda?
- Za koliko prodajete lavandu?
- Možete li mi reći cenu lavande?

Iako su formulacije različite, korisnik u svim slučajevima traži informaciju o ceni biljke. Zadatak sistema jeste da prepozna da je namera korisnika „cena“, da izdvoji naziv biljke „lavanda“ i da na osnovu baze podataka generiše odgovarajući odgovor.

Pored jednostavnih pitanja, sistem treba da podrži i složenije upite kao što su:

„Treba mi biljka za balkon na suncu koja ne traži mnogo vode.“

Kod ovakvog pitanja ne postoji konkretna biljka već skup zahteva koje preporučena biljka treba da ispuni. Sistem mora da prepozna da korisnik traži preporuku i da izdvoji uslove kao što su balkon, sunce i malo vode.

Zbog navedenih razloga problem predstavlja tipičan NLP zadatak koji obuhvata razumevanje jezika, ekstrakciju informacija i generisanje odgovora.

4.2 Analiza tipičnih korisničkih pitanja

Prilikom razvoja sistema analizirane su vrste pitanja koja kupci najčešće postavljaju rasadniku. Na osnovu te analize definisano je nekoliko osnovnih kategorija korisničkih namera.

Prva grupa pitanja odnosi se na cenu proizvoda.

Primeri:

- Koliko košta lavanda?
- Pošto su muškatile?
- Koliko para je tuja?
- Recite mi cenu lavande.

Druga grupa pitanja odnosi se na dostupnost biljaka.

Primeri:

- Imate li lavandu?
- Da li je hortenzija dostupna?
- Mogu li da kupim ružmarin?
- Imate li kadifice?

Treća grupa pitanja odnosi se na preporuke.

Primeri:

- Treba mi biljka za sunce i malo vode.
- Šta preporučujete za balkon?
- Koje biljke uspevaju u hladu?
- Treba mi zimzelena biljka za ogradu.

Četvrta grupa pitanja odnosi se na informacije o konkretnim biljkama.

Primeri:

- Koliko raste lavanda?
- Da li begonija podnosi senku?
- Kolika je visina odrasle tuje?
- Da li šimšir može da se oblikuje?

Peta grupa pitanja odnosi se na lokaciju i dostavu.

Primeri:

- Gde se nalazi rasadnik?
- Koja je vaša adresa?
- Da li dostavljate za Vranje?
- Možete li da dostavite u Bujanovac?

Tokom razvoja sistema dodate su i dodatne kategorije kao što su radno vreme i kontakt informacije.

Primeri:

- Kada radite?
- Koje vam je radno vreme?
- Koji vam je broj telefona?
- Kako mogu da vas kontaktiram?

Analiza ovih pitanja omogućila je definisanje strukture podataka koju sistem treba da izdvaja iz korisničkog upita.

4.3 Struktura baze biljaka

Za potrebe rada kreirana je baza biljaka u CSV formatu. Svaki red predstavlja jednu biljku, dok kolone sadrže njene karakteristike.

Osnovna struktura baze prikazana je u Tabeli 4.1.

Tabela 4.1. Struktura baze biljaka	
Kolona	Opis
naziv	Naziv biljke
cena	Prodajna cena
dostupnost_od	Početak perioda dostupnosti
dostupnost_do	Kraj perioda dostupnosti
visina	Očekivana visina biljke
sunce	Uslovi osvetljenja
voda	Potrebe za zalivanjem
tip	Kategorija biljke
nega	Preporuke za održavanje
opis	Kratak opis biljke

Primer jednog zapisa:

Naziv: Lavanda

Cena: 250 dinara

Dostupnost: mart – oktobar

Visina: 40–80 cm

Sunce: sunce

Voda: malo

Tip: začinska biljka

Opis: Dobra za sunčana mesta i ne traži mnogo vode.

Baza sadrži različite kategorije biljaka:

- sezonsko cveće,
- začinske biljke,
- zimzelene biljke,
- ukrasno drveće,
- ukrasno žbunje.

Ukupno je definisano više desetina biljaka koje omogućavaju generisanje preporuka na osnovu različitih korisničkih zahteva.

4.4 Struktura korisničkog upita

Da bi sistem mogao da obradi korisnički zahtev, svaki upit se prevodi u strukturisani JSON

format.

Primer:

Korisnički upit:

„Treba mi biljka za balkon na suncu.“

Pretvara se u:

```
{  
  "namere": ["preporuka"],  
  "biljka": null,  
  "uslovi": ["balkon", "sunce"],  
  "lokacija": null  
}
```

Ovakav pristup omogućava jednostavnije pretraživanje baze i generisanje odgovora.

U okviru sistema izdvajaju se četiri osnovne vrste informacija:

Namere (Intent)

Predstavlja cilj korisničkog pitanja.

Primer:

"namere": ["cena"]

Biljka

Predstavlja biljku koja se pominje u pitanju.

Primer:

"biljka": "lavanda"

Uslovi

Predstavljaju karakteristike koje korisnik traži.

Primer:

"uslovi": ["sunce", "malo vode"]

Lokacija

Koristi se kod pitanja vezanih za dostavu ili lokaciju rasadnika.

Primer:

"lokacija": "Vranje"

Ovakva reprezentacija omogućava jasnu podelu između faze razumevanja korisničkog jezika i faze generisanja odgovora.

4.5 Test skup korisničkih upita

Za evaluaciju sistema kreiran je poseban skup od 160 korisničkih upita na srpskom jeziku.

Test skup obuhvata različite tipove pitanja:

- pitanja o ceni,
- pitanja o dostupnosti,
- pitanja o preporukama,
- pitanja o informacijama,
- pitanja o dostavi,
- pitanja o lokaciji,

- opšta pitanja.

Posebna pažnja posvećena je uključivanju različitih formulacija koje imaju isto značenje.

Na primer:

- Koliko košta lavanda?
- Pošto je lavanda?
- Koliko para je lavanda?
- Možete li mi reći cenu lavande?

Sve ove rečenice imaju istu nameru, ali koriste različite izraze.

Takođe su uključeni i složeniji primeri sa više uslova:

- Treba mi biljka za balkon na suncu.
- Treba mi biljka za sunce i malo vode.
- Koja biljka uspeva u polusenci?
- Treba mi zimzelena biljka za ogradu.

Pored toga, u test skup su dodata i kombinovana pitanja:

- Imate li lavandu i koliko košta?
- Da li dostavljate za Vranje i kada radite?

Ovakva pitanja predstavljaju veći izazov za sistem jer zahtevaju istovremeno prepoznavanje više namera.

4.6 Ciljevi sistema

Glavni cilj razvijenog sistema jeste automatska obrada korisničkih pitanja i generisanje odgovora na osnovu baze biljaka.

Sistem treba da:

- prepozna korisničku nameru,
- identifikuje biljku ukoliko je pomenuta,
- izdvoji relevantne uslove,
- prepozna lokaciju kada je potrebna,
- pronađe odgovarajuće podatke u bazi,
- generiše razumljiv odgovor za korisnika.

Pored funkcionalne primene u rasadniku, sistem predstavlja i pogodno okruženje za eksperimentalno poređenje zero-shot, one-shot, three-shot i five-shot pristupa korišćenjem velikih jezičkih modela.

Na taj način moguće je analizirati kako broj primera u promptu utiče na sposobnost modela da razume korisničke zahteve i izdvoji relevantne informacije iz prirodnog jezika.

5. Arhitektura predloženog sistema

5.1 Opšti pregled sistema

Predloženi sistem predstavlja NLP chatbot namenjen automatskom odgovaranju na pitanja korisnika rasadnika biljaka. Sistem kombinuje veliki jezički model sa bazom podataka o biljkama kako bi korisničke upite napisane prirodnim jezikom pretvorio u strukturisane informacije i na osnovu njih generisao odgovore.

Za razliku od klasičnih chatbot sistema zasnovanih na pravilima, u ovom radu je korišćen veliki jezički model koji omogućava razumevanje različitih formulacija istog pitanja. Korisnici mogu postavljati pitanja na prirodan način, bez potrebe da koriste unapred definisane komande ili tačno određene izraze.

Rad sistema može se posmatrati kroz nekoliko uzastopnih koraka. Korisnik najpre unosi pitanje, nakon čega se ono prosleđuje velikom jezičkom modelu. Model analizira tekst i izdvaja najvažnije informacije, odnosno nameru korisnika, naziv biljke, uslove koje biljka treba da ispuni i eventualnu lokaciju. Dobijeni rezultat zatim se koristi za pretraživanje baze biljaka i generisanje odgovarajućeg odgovora.

Na ovaj način je postignuto jasno razdvajanje procesa razumevanja jezika i procesa pretrage podataka, što omogućava lakše proširivanje sistema u budućnosti.

5.2 Komponente sistema

Arhitektura sistema sastoji se od četiri osnovne komponente.

U okviru rada korišćena je konzolna aplikacija kroz koju korisnik postavlja pitanja i dobija odgovore. Iako je implementacija jednostavna, ista logika može se kasnije povezati sa web aplikacijom, Instagram porukama ili drugim komunikacionim kanalima.

Druga komponenta je LLM parser. Njegov zadatak je da korisnički tekst pretvori u strukturisani JSON zapis. U ovoj fazi koristi se model qwen 2.5:3b pokrenut lokalno pomoću Ollama platforme. Model ne generiše direktno odgovor korisniku, već vrši analizu upita i izdvajanje relevantnih informacija.

Treću komponentu predstavlja baza biljaka. Podaci o biljkama čuvaju se u CSV datoteci koja sadrži informacije o cenama, dostupnosti, visini, potrebama za zalivanjem, zahtevima za osvetljenje i drugim karakteristikama biljaka.

Poslednju komponentu čini modul za generisanje odgovora. Ovaj modul koristi informacije dobijene od parsera i podatke iz baze biljaka kako bi formirao odgovor koji se prikazuje korisniku.

5.3 Proces obrade korisničkog upita

Kada korisnik postavi pitanje, ono se najpre prosleđuje parseru zasnovanom na velikom jezičkom modelu. Model analizira tekst i generiše JSON objekat koji sadrži izdvojene informacije.

Na primer, za upit:

„Treba mi biljka za balkon na suncu koja ne traži mnogo vode.“

model generiše sledeću strukturu:

```
{
  "namere": ["preporuka"],
  "biljka": null,
  "uslovi": ["balkon", "sunce", "malo vode"],
  "lokacija": null
}
```

Nakon toga sistem obrađuje dobijeni JSON i određuje koju akciju treba izvršiti. Ukoliko je u pitanju cena, pretražuje se odgovarajuća biljka i vraća njena cena. Ako je korisnik postavio pitanje o dostupnosti, prikazuju se informacije o periodu prodaje. Kod preporuka sistem pronalazi biljke koje najbolje odgovaraju navedenim uslovima.

Ovakav pristup omogućava da se različite vrste pitanja obrađuju na jedinstven način bez potrebe za pisanjem velikog broja ručno definisanih pravila.

5.4 Korišćenje velikog jezičkog modela

Veliki jezički model predstavlja centralni deo sistema. Njegova uloga nije da odgovara na pitanja o biljkama na osnovu sopstvenog znanja, već da razume korisnički tekst i izdvoji potrebne informacije.

Model dobija sistemski prompt koji definiše dozvoljene namere, strukturu JSON izlaza i primere pravilno obrađenih upita. Na osnovu tih informacija model generiše strukturisani odgovor koji se zatim koristi u ostatku sistema.

U radu su testirane različite varijante prompta. Poređeni su zero-shot, one-shot, three-shot i five-shot pristupi kako bi se ispitalo da li dodavanje primera poboljšava rezultate. Ovakav pristup omogućio je analizu uticaja broja primera na uspešnost ekstrakcije informacija iz korisničkih upita.

5.5 Generisanje odgovora

Nakon što sistem izdvoji potrebne informacije, generiše se odgovor za korisnika. Za razliku od nekih savremenih chatbot sistema, u ovom radu odgovori nisu generisani pomoću LLM modela, već pomoću unapred definisanih šablona.

Na primer, ukoliko korisnik pita za cenu biljke, odgovor se formira korišćenjem podataka iz baze:

„Lavanda košta 250 dinara.“

Za pitanja o dostupnosti koristi se period prodaje biljke:

„Lavanda je dostupna od marta do oktobra.“

Kod preporuka sistem analizira uslove koje je korisnik naveo i pronalazi biljke sa najvećim brojem poklapanja. Nakon toga prikazuje nekoliko najboljih kandidata zajedno sa kratkim opisom.

Korišćenje šablonskih odgovora omogućava jednostavniju evaluaciju sistema jer se može jasno utvrditi da li su pronađeni tačni podaci iz baze.

5.6 Prednosti predložene arhitekture

Predložena arhitektura ima nekoliko značajnih prednosti. Veliki jezički model omogućava razumevanje različitih formulacija korisničkih pitanja bez potrebe za treniranjem posebnog klasifikatora. Istovremeno, svi podaci o biljkama ostaju u lokalnoj bazi, što omogućava jednostavno ažuriranje cena i informacija bez promene samog modela.

Dodatna prednost jeste modularnost sistema. Svaka komponenta može se nezavisno unapređivati. Na primer, moguće je zameniti korišćeni LLM model novijim modelom, proširiti bazu biljaka ili dodati nove vrste korisničkih namera bez značajnih izmena ostatka sistema.

Zahvaljujući ovakvoj organizaciji, sistem predstavlja dobru osnovu za razvoj naprednijih chatbot rešenja namenjenih rasadnicima, cvećarama i drugim poslovima koji se oslanjaju na komunikaciju sa korisnicima putem prirodnog jezika.

6. Priprema baze biljaka i test skupa upita

6.1 Kreiranje baze biljaka

Za potrebe razvoja sistema kreirana je baza biljaka u CSV formatu. Baza predstavlja izvor znanja koji chatbot koristi prilikom generisanja odgovora korisnicima. Svaka biljka opisana je skupom atributa koji sadrže informacije relevantne za kupce, kao što su cena, period dostupnosti, očekivana visina, potrebe za osvetljenjem, potrebe za zalivanjem, tip biljke, preporuke za negu i kratak opis.

U bazu su uključene različite kategorije biljaka kako bi sistem mogao da odgovori na što veći broj korisničkih zahteva. Pored sezonskog cveća, obuhvaćene su začinske biljke, zimzelene vrste, ukrasno žbunje i ukrasno drveće. Na ovaj način omogućeno je testiranje različitih tipova preporuka i pretraga.

Prilikom kreiranja baze posebna pažnja posvećena je izboru atributa koji se često pojavljuju u korisničkim pitanjima. Na primer, veliki broj kupaca traži biljke koje vole sunce, podnose senku ili zahtevaju malo vode, zbog čega su upravo te karakteristike uključene u bazu.

6.2 Definisane korisničke namere

Kako bi sistem mogao pravilno da razume pitanja korisnika, definisan je skup osnovnih namera koje pokrivaju najčešće situacije u radu rasadnika.

Korišćene su sledeće namere:

- cena,
- dostupnost,
- preporuka,
- informacije,
- lokacija,
- dostava,
- radno vreme,
- kontakt,
- opšte pitanje.

Svaka namera predstavlja određenu vrstu zahteva koju korisnik upućuje sistemu. Na primer, pitanja o ceni proizvoda klasifikuju se kao namera „cena“, dok se pitanja o karakteristikama biljaka svrstavaju u kategoriju „informacije“.

Pored pojedinačnih namera, sistem podržava i kombinovana pitanja kod kojih jedan upit može sadržati više zahteva istovremeno.

Primer:

„Imate li lavandu i koliko košta?“

Kod ovog pitanja sistem prepoznaje dve namere: dostupnost i cenu.

6.3 Definisanje uslova za preporuke

Za potrebe preporučivanja biljaka definisan je skup uslova koji se mogu pojaviti u korisničkim upitima. Ovi uslovi predstavljaju osobine koje korisnik želi da preporučena biljka poseduje.

Neki od najčešće korišćenih uslova su:

- sunce,
- senka,
- polusenka,
- malo vode,
- balkon,
- terasa,
- saksija,
- živa ograda,
- zimzelena,
- mirisna,
- laka nega,
- brz rast.

Pored direktnih naziva uslova, sistem podržava i različite sinonime i jezičke varijacije. Na primer, izrazi „hlad“, „hladovina“ i „nema mnogo sunca“ mapiraju se na uslov „senka“, dok se izraz „ne traži mnogo vode“ prevodi u uslov „malo vode“.

Na taj način povećana je robusnost sistema prilikom rada sa prirodnim jezikom.

6.4 Kreiranje test skupa

Za evaluaciju sistema kreiran je poseban skup od 160 korisničkih upita na srpskom jeziku. Cilj test skupa bio je da obuhvati što veći broj različitih formulacija i realnih pitanja koja korisnici mogu postaviti rasadniku.

U skup su uključena pitanja vezana za:

- cenu biljaka,
- dostupnost proizvoda,
- preporuke,
- informacije o biljkama,
- lokaciju rasadnika,
- dostavu,

- kontakt informacije,
- radno vreme.

Pored jednostavnih pitanja, test skup sadrži i složenije primere sa više uslova, kao i kombinovana pitanja koja zahtevaju prepoznavanje više namera istovremeno.

Na primer:

„Treba mi biljka za balkon na suncu koja ne traži mnogo vode.“
ili

„Imate li lavandu i koliko košta?“

Ovakvi primeri omogućavaju realniju procenu performansi sistema.

6.5 Evaluacioni skup i očekivani izlaz

Za svaki upit u test skupu definisan je očekivani izlaz koji sadrži tačnu nameru, biljku, uslove i lokaciju. Na osnovu toga moguće je automatski uporediti rezultat koji generiše model sa unapred definisanim rešenjem.

Primer jednog testa prikazan je u Tabeli 6.1.

Tabela 6.1. Primer evaluacionog zapisa

Element	Vrednost
Upit	Koliko košta lavanda?
Očekivana namera	cena
Očekivana biljka	lavanda
Očekivani uslovi	-
Očekivana lokacija	-

Na osnovu poređenja očekivanih i dobijenih vrednosti računata je tačnost sistema za svaku komponentu pojedinačno, kao i ukupna tačnost kompletnog JSON izlaza.

Na ovaj način obezbeđena je objektivna evaluacija performansi različitih pristupa korišćenih u radu.

7. Implementacija sistema

7.1 Tehnologije i alati

Implementacija sistema realizovana je u programskom jeziku Python zbog njegove široke primene u oblasti obrade prirodnih jezika i mašinskog učenja. Za rad sa tabelarnim podacima korišćena je biblioteka Pandas, dok je za učitavanje baze biljaka korišćen CSV format.

Veliki jezički model pokretan je lokalno pomoću platforme Ollama, pri čemu je korišćen model qwen 2.5:3b. Na ovaj način omogućeno je izvršavanje sistema bez potrebe za korišćenjem eksternih API servisa i bez dodatnih troškova.

7.2 Implementacija parsera

Centralni deo sistema predstavlja parser korisničkih upita. Njegov zadatak je da tekstualni upit pretvori u strukturisani JSON zapis koji sadrži informacije potrebne za dalju obradu.

Korisnički upit se prosleđuje velikom jezičkom modelu zajedno sa sistemskim promptom koji definiše dozvoljene namere, strukturu izlaza i nekoliko primera pravilno obrađenih pitanja. Model zatim generiše JSON objekat koji sadrži prepoznate namere, naziv biljke, uslove i lokaciju.

Nakon generisanja JSON-a primenjuju se dodatne funkcije za normalizaciju rezultata. Njihov cilj je ispravljanje različitih padežnih oblika, sinonima i tipičnih grešaka koje model može napraviti prilikom ekstrakcije informacija.

7.3 Pretraga baze biljaka

Nakon uspešne obrade upita sistem koristi dobijene informacije za pretragu baze biljaka. U zavisnosti od prepoznate namere izvršava se odgovarajuća funkcija.

Kod pitanja o ceni i dostupnosti pretražuje se konkretna biljka i vraćaju se njeni podaci iz baze. Kod pitanja o preporukama sistem filtrira biljke prema uslovima koje je korisnik naveo i pronalazi one koje najbolje odgovaraju zahtevu.

Za preporuke je implementirano jednostavno rangiranje zasnovano na broju poklopljenih uslova. Biljke sa najvećim brojem poklapanja prikazuju se na vrhu liste preporuka.

7.4 Generisanje odgovora

Odgovori se generišu pomoću unapred definisanih šablona. Ovakav pristup omogućava jednostavno testiranje i evaluaciju sistema, jer se odgovori formiraju direktno na osnovu podataka iz baze.

Na primer, za pitanje o ceni generiše se odgovor koji sadrži naziv biljke i cenu, dok se za preporuke prikazuje lista biljaka sa kratkim opisima i obrazloženjem zbog čega su izabrane. Posebna pažnja posvećena je podršci za kombinovana pitanja kod kojih korisnik istovremeno traži više informacija. U takvim slučajevima sistem generiše više odgovora koji se objedinjeno prikazuju korisniku.

7.5 Organizacija projekta

Implementacija je podeljena na nekoliko logičkih celina. Parser je zadužen za razumevanje korisničkog jezika, modul za preporuke vrši pretragu baze biljaka, dok poseban deo sistema generiše odgovore za korisnika. Ovakva organizacija omogućava jednostavno održavanje i dalji razvoj sistema.

Zahvaljujući modularnoj strukturi moguće je lako zameniti korišćeni model, proširiti bazu biljaka ili dodati nove tipove korisničkih pitanja bez značajnih izmena ostatka sistema.

8. Eksperimentalni rezultati i evaluacija sistema

8.1 Metodologija evaluacije

Kako bi se procenila uspešnost predloženog sistema, sprovedena je evaluacija nad test skupom od 160 korisničkih upita na srpskom jeziku. Test skup sadrži pitanja različitih tipova, uključujući pitanja o cenama, dostupnosti biljaka, preporukama, informacijama o biljkama, lokaciji, dostavi, kontaktu i radnom vremenu.

Za svaki upit unapred je definisan očekivani JSON izlaz koji sadrži tačnu nameru, naziv biljke, uslove i lokaciju. Rezultati generisani od strane modela upoređivani su sa očekivanim vrednostima.

Evaluacija je izvršena kroz četiri pokazatelja:

- tačnost prepoznavanja namere,
- tačnost prepoznavanja biljke,
- tačnost izdvajanja uslova,
- ukupna tačnost kompletnog JSON izlaza.

Ukupna tačnost smatra se najstrožim kriterijumom jer zahteva da svi elementi JSON strukture budu tačno prepoznati.

8.2 Eksperimentalne postavke

U radu su testirane pet varijante promptovanja velikog jezičkog modela:

- Zero-shot pristup (bez primera),
- One-shot pristup (jedan primer),
- Three-shot pristup (tri primera),
- Five-shot pristup (pet primera).
- Ten-shot pristup (deset primera).

Sve varijante koristile su isti model, istu bazu biljaka i isti skup testnih pitanja. Jedina razlika između eksperimenata bio je broj primera uključenih u sistemski prompt.

Cilj eksperimenta bio je da se ispita kako broj primera utiče na sposobnost modela da razume korisničke upite i pravilno izdvoji relevantne informacije.

8.3 Poređenje Rule-based, LLM-only i hibridnog pristupa

Pre sprovođenja zero-shot i N-shot eksperimenata izvršeno je poređenje tri različita pristupa za obradu korisničkih upita:

- Rule-based sistem
- LLM-only sistem
- Hibridni sistem

Cilj ovog poređenja bio je da se utvrdi koji pristup daje najbolji odnos između tačnosti, stabilnosti i sposobnosti razumevanja prirodnog jezika u domenu rasadnika biljaka.

Rule-based sistem zasnovan je isključivo na ručno definisanim pravilima za prepoznavanje namera, biljaka, uslova i lokacija. Ovakav pristup daje veoma stabilne rezultate kod jednostavnih i očekivanih formulacija pitanja, posebno kada korisnik koristi unapred poznate obrasce kao što su „Koliko košta lavanda?“, „Imate li muškatle?“ ili „Da li dostavljate za Vranje?“. Prednost ovog pristupa je potpuna kontrola nad izlazom i odsustvo halucinacija.

Međutim, tokom testiranja uočena su značajna ograničenja. Sistem je često imao problema sa slobodnije formulisanim upitima i implicitno izraženim zahtevima. Na primer, za upit „Nemam mnogo sunca“ nije uspeo da zaključi da korisnik zapravo traži biljke za senku. Takođe, kod pitanja „Koje biljke podnose sušu?“ nije uspevao da poveže pojam suše sa uslovom „malo vode“, dok za upit „Šta preporučujete za početnika?“ nije prepoznavao uslov „laka nega“. Slično tome, kod pitanja „Koja zimzelena biljka je najbolja za ogradu?“ sistem nije uspevao da istovremeno izdvoji uslove „zimzelena“ i „živa ograda“.

Na kompletnom test skupu od 160 upita rule-based sistem ostvario je tačnost od 92.50% za prepoznavanje namere i 100% za identifikaciju biljaka, ali samo 72.50% za izdvajanje uslova. Ukupna tačnost kompletnog JSON izlaza iznosila je 68.12%.

Za razliku od toga, LLM-only pristup koristi veliki jezički model Qwen2.5:3b za direktno generisanje kompletne JSON strukture. Ovakav pristup pokazao je znatno bolje razumevanje prirodnog jezika, sinonima i neformalnih formulacija. Model je uspešno prepoznavao značenja izraza poput „nemam mnogo sunca“, „biljka za početnika“, „biljka za vikendicu“, „podnosi sušu“ ili „cveta celo leto“, čak i kada takve formulacije nisu bile eksplicitno definisane pravilima.

Ipak, tokom testiranja primećeni su i ozbiljni problemi karakteristični za velike jezičke modele. Model je često generisao dodatne namere koje nisu postojale u korisničkom pitanju, birao konkretne biljke i kada korisnik nije tražio određenu biljku, kao i dodavao uslove koji nisu bili pomenuti u upitu. Na primer, za pitanje „Pošto je petunija?“ model je umesto namere „cena“ generisao preporuku i dodatni uslov „sunce“. Kod upita „Koja biljka podnosi senku?“ model je proizvoljno izabrao biljku „hrizantema“, iako korisnik nije naveo nijednu biljku. Takođe su zabeleženi slučajevi generisanja dodatnih uslova kao što su „ukrasna“, „zimzelena“ ili „leto“, iako takvi zahtevi nisu postojali u korisničkom pitanju.

Na test skupu od 160 upita LLM-only sistem ostvario je 77.50% tačnosti za nameru, 85.62% za biljku i 70.00% za uslove, dok je ukupna tačnost kompletnog JSON izlaza iznosila svega 55.62%. Rezultati pokazuju da model dobro razume značenje upita, ali nije dovoljno pouzdan za direktnu upotrebu bez dodatne kontrole izlaza.

Zbog navedenih nedostataka razvijen je hibridni pristup, koji kombinuje prednosti oba sistema. Ideja ovog pristupa nije bila da se u potpunosti zamene ručno definisana pravila, već da se iskoriste prednosti LLM modela u razumevanju prirodnog jezika, dok se konačni rezultat stabilizuje pomoću pravila.

Kada korisnik unese upit, on se najpre prosleđuje modelu Qwen2.5:3b preko Ollama okruženja. Model generiše inicijalni JSON koji sadrži polja namere, biljka, uslovi i lokacija. Nakon toga se primenjuje rule-based sloj validacije i korekcije.

Tekst se prvo normalizuje uklanjanjem dijakritika, interpunkcije i viška razmaka. Zatim se biljke proveravaju pomoću unapred definisane mape biljaka i njihovih padežnih oblika. Na primer, izrazi „lavande“, „lavandu“ i „lavanda“ svode se na jedinstveni oblik „lavanda“. Kod opštih preporuka sistem ne dozvoljava LLM modelu da samostalno bira konkretnu biljku, čime se eliminiše veliki broj halucinacija.

Namere se određuju kombinovanjem LLM izlaza i rule-based pravila. Time je omogućeno prepoznavanje složenijih i kombinovanih pitanja kao što je „Imate li lavande i koja je cena?“, gde sistem istovremeno prepoznaje namere „dostupnost“ i „cena“.

Uslovi se određuju hibridno. LLM model omogućava razumevanje slobodno formulisanih zahteva poput „nešto što lepo cveta“, „nemam vremena za zalivanje“ ili „biljka za vikendicu“, dok pravila obezbeđuju stabilno prepoznavanje uslova kao što su „sunce“, „senka“, „terasa“, „živa ograda“, „kamenjar“ i „saksija“. Nakon spajanja rezultata uklanjaju se kontradiktorni ili nerelevantni uslovi.

Lokacije se prvenstveno određuju pomoću unapred definisane mape gradova, dok se LLM rezultat koristi samo kao pomoćna informacija uz dodatnu validaciju.

Na kompletnom test skupu analizirane su različite varijante hibridnog sistema (zero-shot, one-shot, three-shot, five-shot i ten-shot). Najbolje rezultate ostvario je five-shot pristup sa ukupnom tačnošću JSON izlaza od 58.13%, dok su ostale varijante ostvarile rezultate između 49% i 56%. Međutim, dodatna analiza na nezavisnom skupu od 30 realističnih korisničkih upita pokazala je da konačna hibridna implementacija daje značajno bolje rezultate od svih pojedinačnih pristupa.

Tabela 8.1 prikazuje procenu uspešnosti na dodatnom skupu upita od 30 pitanja slobodno formulisanih van šablona:

- Rules-only: približno 56.7%
- LLM-only: približno 66.7%
- Hibridni: približno 83.3%

Na ovom skupu pitanja hibridni sistem pokazao se kao najstabilnije rešenje. Posebno se istakao kod neformalnih formulacija poput „Jel ima ona biljka što privlači leptire?“, „Treba mi nešto za deo dvorišta gde sunce dolazi samo ujutru“, „Koja biljka može da preživi bez mnogo zalivanja?“ ili „Imate li još onih malih tuja?“. U takvim slučajevima rule-based sistem uglavnom nije mogao da razume značenje upita, dok je LLM-only pristup često generisao dodatne ili netačne informacije. Hibridni sistem uspeo je da spoji semantičko razumevanje LLM modela sa stabilnošću rule-based validacije.

Na osnovu svih sprovedenih eksperimenata može se zaključiti da rule-based pristup daje najbolje rezultate kod šablonskih pitanja, LLM-only pristup pokazuje najbolje razumevanje prirodnog jezika, dok hibridni sistem postiže najbolji balans između tačnosti, robusnosti i praktične upotrebljivosti. Zbog toga je upravo ovaj pristup izabran kao konačno rešenje u okviru razvijenog NLP asistenta za rasadnik biljaka.

8.4 Rezultati evaluacije prvog parsera i modela llama3.2:3b

Dobijeni rezultati prikazani su u Tabeli 8.1.

Tabela 8.1. Rezultati prve evaluacije

Pristup	Tačnost namere	Tačnost biljke	Tačnost uslova	Ukupna tačnost JSON-a
Zero-shot	93.12%	46.25%	71.25%	41.25%
One-shot	92.50%	54.37%	71.25%	43.75%
Three-shot	92.50%	75.00%	75.00%	55.00%
Five-shot	90.62%	84.38%	76.88%	61.25%

Rezultati pokazuju da povećanje broja primera uglavnom dovodi do poboljšanja kvaliteta ekstrakcije informacija. Najveće unapređenje primećeno je kod prepoznavanja biljaka, gde je tačnost porasla sa 46.25% kod zero-shot pristupa na 84.38% kod five-shot pristupa.

Kod prepoznavanja uslova takođe je zabeležen napredak, mada je on bio manje izražen. Tačnost namere ostala je visoka kod svih pristupa, što pokazuje da model relativno lako prepoznaje osnovni cilj korisničkog pitanja čak i bez dodatnih primera.

Najvažniji pokazatelj predstavlja ukupna tačnost JSON izlaza, koja je porasla sa 41.25% na 61.25%, što potvrđuje da few-shot pristup značajno doprinosi kvalitetu sistema.

8.5 Rezultati evaluacije krajnjeg parsera i modela qwen2.5:3b

Nakon razvoja i testiranja različitih pristupa za obradu korisničkih upita izvršena je evaluacija konačnog parsera na test skupu od 160 pitanja. Tokom eksperimenta analizirani su Rule-based

sistem, LLM-only sistem i više varijanti hibridnog pristupa zasnovanog na kombinaciji velikog jezičkog modela i ručno definisanih pravila.

Tabela 8.1. Rezultati krajnje evaluacije

Pristup	Tačnost namere	Tačnost biljke	Tačnost uslova	Ukupna tačnost JSON-a
Rules-only	92.50%	100.00%	72.50%	68.12%
LLM-only	77.50%	85.62%	70.00%	55.62%
Hibrid Zero-shot	71.88%	100.00%	60.62%	49.38%
Hibrid One-shot	81.25%	100.00%	60.62%	54.37%
Hibrid Three-shot	82.50%	100.00%	56.88%	53.12%
Hibrid Five-shot	85.00%	100.00%	61.88%	58.13%
Hibrid Ten-shot	82.50%	100.00%	61.25%	55.62%

Rezultati pokazuju da je Rule-based sistem ostvario najveću ukupnu tačnost na ovom test skupu. Tačnost prepoznavanja namere iznosila je 92.50%, tačnost prepoznavanja biljke 100.00%, tačnost izdvajanja uslova 72.50%, dok je ukupna tačnost kompletnog JSON izlaza iznosila 68.12%.

LLM-only pristup ostvario je 77.50% tačnosti za nameru, 85.62% za biljku i 70.00% za uslove, uz ukupnu tačnost JSON izlaza od 55.62%.

Kod hibridnih pristupa najbolji rezultat ostvario je Five-shot model sa ukupnom tačnošću od 58.13%, dok su ostale varijante ostvarile rezultate između 49.38% i 55.62%.

Na prvi pogled može se zaključiti da je Rule-based sistem najbolji zbog najveće numeričke tačnosti. Međutim, detaljnija analiza pokazuje da je test skup dominantno sastavljen od šablonskih pitanja kao što su „Koliko košta lavanda?“, „Imate li muškatle?“ ili „Da li dostavljate za Vranje?“. Kod ovakvih pitanja pravila imaju prirodnu prednost jer su unapred definisana upravo za takve obrasce.

Zbog toga je sprovedena dodatna analiza na posebnom skupu od 30 realističnih korisničkih pitanja koja su sadržala neformalne izraze, sinonime i slobodnije formulacije. Na tom skupu rezultati su bili značajno drugačiji. Rule-based sistem ostvario je približno 56.7% tačnosti, LLM-only sistem oko 66.7%, dok je hibridni parser ostvario približno 83.3% tačnosti.

Ovi rezultati pokazuju da ukupna numerička tačnost na šablonskom test skupu ne prikazuje u potpunosti ponašanje sistema u realnim uslovima rada. U situacijama kada korisnici koriste prirodan govor, neformalne izraze i implicitno formulisane zahteve, hibridni parser pokazuje značajno bolje performanse od čistog rule-based pristupa.

Pored evaluacije parsera razvijena je i skripta recommendation_engine.py koja demonstrira praktičnu upotrebu sistema u realnom vremenu. Nakon unosa korisničkog pitanja parser generiše

JSON strukturu sa prepoznatim namerama, biljkama, uslovima i lokacijama, dok recommendation engine na osnovu tih podataka generiše konkretan odgovor korisniku. Na primer, za pitanje „Dobar dan, cena lavande i da li imate?“ sistem je uspešno prepoznao namere cena i dostupnost i vratio informaciju o ceni i dostupnosti biljke. Za upit „Imate neku preporuku za hladovinu?“ sistem je izdvojio uslov senka i pronašao odgovarajuće biljke iz baze podataka. Time je potvrđeno da parser nije korišćen samo za eksperimentalnu evaluaciju, već predstavlja funkcionalnu komponentu chatbot sistema za rasadnik biljaka.

8.6 Analiza uspešnih upita

Analiza uspešno obrađenih upita pokazuje da razvijeni parser veoma dobro funkcioniše kod velikog broja tipičnih pitanja koja se mogu očekivati u komunikaciji korisnika sa rasadnikom. Posebno dobre rezultate sistem ostvaruje kod pitanja vezanih za cenu, dostupnost, dostavu, lokaciju i kontakt informacije.

Kod upita kao što su „Koliko košta lavanda?“, „Imate li muškatle?“ ili „Da li dostavljate za Vranje?“ sistem gotovo bez greške prepoznaje nameru, biljku i eventualnu lokaciju. Tačnost identifikacije biljaka dostigla je 100%, što pokazuje da kombinacija mapa biljaka, normalizacije teksta i validacije daje veoma pouzdane rezultate.

Pored šablonskih pitanja, hibridni parser pokazao je značajnu prednost kod slobodnije formuliranih upita. Na primer, uspešno su obrađeni upiti poput „Jel ima ona biljka što privlači leptire?“, „Treba mi nešto za deo dvorišta gde sunce dolazi samo ujutru“, „Koja biljka može da preživi bez mnogo zalivanja?“ ili „Imate li još onih malih tuja?“. Ovakva pitanja predstavljaju izazov za klasične rule-based sisteme jer korisnik ne koristi unapred očekivane fraze.

Uspešni primeri pokazuju da LLM model dobro razume značenje izraza kao što su „hladovina“, „severna strana kuće“, „bez mnogo zalivanja“, „zaklanjanje pogleda“, „početnik“, „kamenjar“ ili „mirisna biljka“. Nakon toga rule-based sloj vrši normalizaciju i validaciju rezultata, čime se sprečava generisanje nepostojećih biljaka ili lokacija.

Posebno značajna karakteristika sistema jeste mogućnost prepoznavanja višestrukih namera. Na primer, za pitanje „Imate li lavandu i koja je cena?“ parser uspešno prepoznaje i nameru dostupnost i nameru cena, što omogućava generisanje kompletnog odgovora korisniku.

Rezultati pokazuju da razvijeni sistem može uspešno da obradi kako formalno postavljena pitanja tako i neformalne korisničke upite karakteristične za komunikaciju putem društvenih mreža, chat aplikacija i chatbot sistema.

8.7 Analiza grešaka

Analiza grešaka pokazuje da najveći izazovi ne potiču od identifikacije biljaka, već od prepoznavanja namera i izdvajanja uslova iz korisničkih upita.

Kod Rule-based sistema najveći problem predstavljaju sinonimi i slobodnije formulacije. Na primer, pitanja poput „Nemam mnogo sunca“, „Šta da zasadim ispred kuće?“ ili „Treba mi nešto zeleno tokom cele godine“ zahtevaju razumevanje značenja rečenice, a ne samo prepoznavanje unapred definisanih ključnih reči. Ukoliko određena formulacija nije eksplicitno predviđena pravilima, sistem često vraća opštu nameru ili ne uspeva da izdvoji odgovarajući uslov.

Kod LLM-only sistema dominantan problem predstavljaju halucinacije. Model često generiše dodatne informacije koje korisnik nije naveo. Uočeni su slučajevi u kojima model bira konkretnu biljku iako korisnik traži samo preporuku, dodaje dodatne uslove poput „ukrasna“, „zimzelena“, „leto“ ili „puno vode“, kao i situacije u kojima pogrešno određuje nameru pitanja. Posebno često dolazi do mešanja namera preporuka i informacije.

Analiza grešaka kod hibridnog sistema pokazuje da se najveći broj preostalih problema javlja upravo u delu koji se odnosi na uslove. Korisnici isti zahtev mogu izraziti na veliki broj načina. Na primer, izrazi „nemam mnogo sunca“, „severna strana kuće“ i „hladovina“ svi bi trebalo da budu mapirani na uslov „senka“. Slično tome, izrazi „podnosi sušu“, „zaboravim zalivanje“ ili „nemam vremena za zalivanje“ trebalo bi da budu povezani sa uslovom „malo vode“.

Druga značajna grupa grešaka odnosi se na razlikovanje preporuke i informacije. Na primer, pitanje „Koja biljka je dobra za živu ogradu?“ predstavlja zahtev za preporuku, dok pitanje „Da li je fotinija dobra za živu ogradu?“ predstavlja zahtev za informacijom o konkretnoj biljci. Ovakve razlike su često suptilne i zahtevaju dublje razumevanje konteksta.

Treći problem predstavljaju pitanja van domena rasadnika. U takvim slučajevima očekivano je vraćanje namere „opste“, dok LLM model ponekad pokušava da pronađe vezu sa postojećim kategorijama i generiše nepovezane rezultate.

Analiza grešaka pokazuje da najveći potencijal za unapređenje sistema postoji upravo u proširivanju mape sinonima, dodatnoj validaciji uslova dobijenih od LLM modela i preciznijem razlikovanju preporuke i informacije.

8.8 Diskusija rešenja

Rezultati sprovedenih eksperimenata pokazuju da ne postoji univerzalno najbolji pristup za obradu korisničkih upita, već da uspešnost sistema zavisi od prirode podataka i načina na koji korisnici formulišu pitanja.

Rule-based sistem ostvario je najbolju numeričku tačnost na osnovnom test skupu od 160 pitanja. Međutim, detaljna analiza pokazuje da je veliki deo tog skupa sastavljen od šablonskih pitanja koja su veoma slična pravilima definisanim u sistemu. Zbog toga visoka tačnost ne znači nužno da će isti sistem biti najbolji u realnoj komunikaciji sa korisnicima.

Sa druge strane, LLM-only sistem pokazao je značajno bolje razumevanje prirodnog jezika. Model uspešno razume sinonime, neformalne formulacije i implicitne zahteve korisnika. Ipak, nedostatak stroge kontrole izlaza dovodi do pojave halucinacija, dodavanja nepostojećih uslova i

pogrešnog određivanja namera. Takvo ponašanje nije prihvatljivo za poslovne sisteme koji moraju davati konzistentne i pouzdane odgovore.

Zbog toga je razvijen hibridni pristup. Osnovna ideja ovog rešenja jeste da se LLM koristi za razumevanje značenja korisničkog upita, dok se konačni rezultat validira i koriguje pomoću pravila. Na taj način sistem zadržava sposobnost razumevanja prirodnog jezika, ali istovremeno smanjuje mogućnost generisanja netačnih informacija.

Posebno je značajan rezultat dobijen na dodatnom skupu od 30 realističnih korisničkih pitanja. Dok je Rule-based sistem ostvario približno 56.7% tačnosti, a LLM-only sistem oko 66.7%, hibridni parser dostigao je približno 83.3% tačnosti. Ovi rezultati pokazuju da je hibridni pristup znatno pogodniji za realne korisničke scenarije u kojima se pitanja postavljaju spontano, neformalno i bez unapred definisane strukture.

Može se zaključiti da Rule-based pristup najbolje funkcioniše kod šablonskih pitanja, LLM-only pristup kod razumevanja prirodnog jezika, dok hibridni pristup uspešno kombinuje prednosti oba sistema. Upravo zbog toga hibridni parser predstavlja najpraktičnije rešenje za implementaciju chatbot sistema u manjim domenima kao što su rasadnici, ordinacije, frizerski saloni, auto-servisi i drugi lokalni biznisi.

Rezultati rada potvrđuju da kombinacija velikih jezičkih modela i ručno definisanih pravila predstavlja efikasan pristup za izgradnju pouzdanih domen-specifičnih NLP sistema. Budući razvoj sistema mogao bi uključivati proširenje baze sinonima, napredniju validaciju LLM izlaza, finije razlikovanje namera i evaluaciju na većim skupovima realnih korisničkih pitanja. Takva unapređenja mogla bi dodatno povećati robusnost i praktičnu primenljivost razvijenog rešenja.

9. Mogućnosti unapređenja sistema

Iako ostvareni rezultati pokazuju da sistem uspešno obrađuje veliki broj korisničkih upita, postoji više mogućnosti za njegovo dalje unapređenje.

Jedno od najvažnijih unapređenja odnosi se na proširenje skupa testnih podataka. Veći broj upita sa različitim formulacijama omogućio bi precizniju evaluaciju sistema i bolju procenu njegovih performansi u realnim uslovima. Posebnu pažnju trebalo bi posvetiti pitanjima koja sadrže negacije, sinonime i složenije jezičke konstrukcije.

Dodatna poboljšanja mogu se ostvariti kroz unapređenje normalizacije naziva biljaka. Trenutna verzija sistema koristi ručno definisana pravila za obradu padežnih oblika i najčešćih varijacija naziva biljaka. Uvođenjem naprednijih metoda za obradu srpskog jezika moguće je dodatno smanjiti broj grešaka prilikom prepoznavanja biljaka.

Takođe, sistem bi mogao biti proširen podrškom za veći broj korisničkih namera. Pored postojećih funkcionalnosti, moguće je dodati pitanja vezana za akcijske cene, rezervacije biljaka, savete za sadnju, bolesti biljaka i druge informacije koje su korisnicima često potrebne.

Značajno unapređenje predstavljalo bi povezivanje sistema sa društvenim mrežama i aplikacijama za komunikaciju. Na taj način chatbot bi mogao automatski da odgovara na poruke pristigle putem Instagrama, Facebook-a ili drugih platformi, čime bi se dodatno povećala njegova praktična vrednost.

Moguće je i korišćenje naprednijih velikih jezičkih modela sa većim brojem parametara. Takvi modeli uglavnom ostvaruju bolje rezultate u razumevanju prirodnog jezika, ali zahtevaju više računarskih resursa za izvršavanje.

Pored toga, zanimljiv pravac budućeg razvoja predstavlja kombinacija LLM pristupa sa tehnikama pretrage baze znanja (Retrieval-Augmented Generation – RAG). U tom slučaju model bi odgovore generisao na osnovu podataka pronađenih u bazi biljaka, što bi omogućilo prirodnije i detaljnije odgovore uz zadržavanje tačnosti informacija.

Na kraju, sistem bi mogao biti implementiran kao web ili mobilna aplikacija namenjena stvarnim korisnicima rasadnika. Time bi se omogućilo testiranje u realnom okruženju i prikupljanje povratnih informacija koje bi bile korisne za dalji razvoj i unapređenje sistema.

10. Zaključak

U ovom radu prikazan je razvoj chatbot sistema za rasadnik biljaka zasnovanog na velikim jezičkim modelima i N-shot pristupu. Cilj rada bio je da se ispita najbolji pristup za formiranje parsera za neformalna pitanja korisnika kao i mogućnost korišćenja LLM modela za razumevanje korisničkih upita na srpskom jeziku i njihovo pretvaranje u strukturisani oblik pogodan za dalju obradu.

Razvijeni sistem koristi veliki jezički model za prepoznavanje korisničkih namera, izdvajanje naziva biljaka, uslova i lokacija, nakon čega pretražuje bazu biljaka i generiše odgovarajući odgovor. Za potrebe evaluacije kreiran je skup od 160 testnih upita koji obuhvataju različite tipove pitanja karakteristične za rad rasadnika.

Eksperimentalni rezultati pokazali su da veliki jezički modeli mogu uspešno da rešavaju zadatke razumevanja korisničkih upita bez dodatnog treniranja modela. Posebno je potvrđeno da N-shot pristupi poboljšavaju kvalitet ekstrakcije informacija u odnosu na zero-shot pristup. Najbolje rezultate ostvario je five-shot pristup, koji je postigao najveću ukupnu tačnost JSON izlaza.

Analiza grešaka pokazala je da najveći izazovi i dalje postoje kod obrade padežnih oblika, sinonima, negacija i složenijih korisničkih zahteva. Ipak, dobijeni rezultati potvrđuju da je moguće razviti funkcionalan NLP sistem za usko definisan domen bez potrebe za kreiranjem velikih označenih skupova podataka i treniranjem posebnih klasifikacionih modela.

Na osnovu sprovedenih eksperimenata može se zaključiti da veliki jezički modeli predstavljaju efikasno rešenje za razvoj specijalizovanih chatbot sistema. Predloženi sistem pokazuje potencijal za praktičnu primenu u rasadnicima i sličnim poslovnim okruženjima, uz mogućnost daljeg proširenja i unapređenja kroz integraciju sa stvarnim komunikacionim kanalima i naprednijim modelima obrade prirodnog jezika.